

Radar Acústico Basado en ESP32: Diseño, Implementación y Validación Experimental de un Sistema de Detección de Ecos mediante Correlación y FFT

Emanuel Rojas, Mariana González
Escuela de Ingeniería Electrónica
Instituto Tecnológico de Costa Rica
CE1110 – Análisis de Señales Mixtas
Correo: emmrojas@estudiantec.cr

Abstract—This paper presents the design, software validation, and ongoing hardware implementation of a low-cost monostatic acoustic radar built on an ESP32 microcontroller. The system emits a linear frequency-modulated (chirp) acoustic pulse swept from 2 kHz to 8 kHz through a speaker and estimates the time of flight of its echo, captured with a microphone, through cross-correlation. Prior to the embedded port, every building block – the discrete Fourier transform (DFT), a custom Cooley-Tukey radix-2 FFT, and both direct and FFT-based cross-correlation – was implemented from scratch and validated in Python against a numerical reference, and stress-tested under signal-to-noise ratios from -5 dB to 20 dB and under multiple simultaneous echoes. Measured results show the custom FFT is nearly 29 times faster than the direct DFT at $N = 4096$ samples (17.2 ms versus 497.3 ms), while direct correlation remains cheaper than FFT-based correlation for the small window sizes actually used on the microcontroller. The embedded system computes three parallel distance candidates – direct time-domain correlation, library-based FFT correlation, and a background-subtraction estimator that cancels static environmental reflections against a no-object calibration baseline – using a guard interval derived directly from the theoretical minimum-range model. As of the latest hardware tests the system consistently reports accurate distances at short range (validated at 15 cm and 22 cm), while reliability beyond that range is still limited by environmental clutter competing with the weakening target echo, and reconciling the three candidates into a single trusted output remains ongoing work. The results nonetheless confirm that the theoretical DSP concepts of the course translate into a working, resource-constrained embedded system, and they surface concrete, physically-grounded engineering trade-offs still to be resolved.

Index Terms—acoustic radar, embedded systems, cross-correlation, Fast Fourier Transform, time-of-flight, ESP32

I. INTRODUCCIÓN

El radar es, en su forma más elemental, un sistema que estima la distancia a un objetivo midiendo el tiempo que tarda una señal en viajar hasta él y regresar como eco. Este proyecto traslada ese principio al dominio acústico audible: un altavoz emite un pulso conocido y un micrófono capta su reflexión, de modo que la distancia se obtiene a partir del retardo estimado entre ambas señales. El interés del curso CE1110 – Análisis de Señales Mixtas no es únicamente construir el

dispositivo, sino aplicar de forma explícita los conceptos de la asignatura – series y transformada de Fourier, la DFT y la FFT, sistemas LTI, convolución y correlación – primero en un entorno de prototipado flexible y luego en un microcontrolador con restricciones estrictas de memoria y tiempo real.

El proyecto se desarrolló en dos grandes fases. En la primera, todos los algoritmos de procesamiento digital de señales (DFT directa, FFT propia, correlación directa y correlación mediante FFT) se implementaron y validaron en Python, comparando su exactitud numérica contra bibliotecas de referencia y caracterizando su costo computacional y su robustez ante ruido. En la segunda fase, el subconjunto de algoritmos apropiado para operación en tiempo real se portó a un ESP32, junto con la generación de la señal transmitida, la captura de la señal recibida y la estimación de distancia, desplegando el resultado en una pantalla LCD.

El resto de este documento se organiza de la siguiente manera. La sección II presenta el marco teórico que sustenta el diseño, cubriendo la DFT y la FFT, la correlación cruzada como filtro adaptado para estimación de retardo, la señal chirp y el límite físico de rango mínimo de un radar pulsado, así como las restricciones propias de la implementación embebida. La sección III describe la metodología experimental y presenta los resultados obtenidos tanto en la etapa de validación en software como en la etapa de implementación en hardware, junto con su análisis. La sección IV expone las conclusiones del trabajo y la sección V presenta las recomendaciones para etapas futuras del proyecto.

II. MARCO TEÓRICO

A. Transformada Discreta de Fourier y Transformada Rápida de Fourier

La DFT de una secuencia $x[n]$ de N muestras se define como

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad (1)$$

y su cálculo directo requiere $O(N^2)$ operaciones. El algoritmo de Cooley-Tukey de decimación en tiempo (radix-2) explota la periodicidad y simetría de los factores $e^{-j2\pi kn/N}$ para descomponer recursivamente la DFT de N muestras en dos DFT de $N/2$ muestras (submuestras pares e impares), reduciendo el costo a $O(N \log_2 N)$ [1], [2]. Esta reducción es la que hace viable procesar ventanas de cientos de muestras en un microcontrolador con recursos limitados.

B. Correlación cruzada como filtro adaptado

Dada una señal transmitida conocida $x[n]$ y una señal recibida $y[n]$ que contiene una copia atenuada y retardada de $x[n]$, la correlación cruzada

$$r_{xy}[k] = \sum_n x[n] y[n+k] \quad (2)$$

presenta un máximo en el valor de k que corresponde al retardo real entre ambas señales [5]. Este procedimiento equivale a un filtro adaptado (*matched filter*), ampliamente utilizado en sistemas de radar para maximizar la relación señal-ruido en la detección del eco [3], [4]. La misma operación puede calcularse en el dominio de la frecuencia mediante el teorema de correlación,

$$r_{xy} = \text{IFFT} \left(\overline{X[k]} Y[k] \right), \quad (3)$$

donde $\overline{X[k]}$ es el conjugado de la transformada de la señal transmitida. Este método requiere *zero-padding* de ambas señales a una longitud potencia de dos compatible con la FFT radix-2.

C. Señal chirp y límite físico de rango mínimo

Como señal transmitida se emplea un chirp lineal (barrido lineal de frecuencia) entre 2 kHz y 8 kHz. Frente a un tono puro, el chirp distribuye su energía en un ancho de banda mayor, lo que produce un pico de correlación más angosto y por tanto una mejor resolución temporal para estimar el retardo. En un radar pulsado monoestático – donde el mismo transductor idealmente emite y luego escucha –, el eco de un objetivo muy cercano regresa antes de que termine de emitirse el pulso, quedando indistinguible de la señal transmitida. Esto impone un rango mínimo teórico

$$R_{\min} \approx \frac{v_{\text{sonido}} T_{\text{chirp}}}{2}, \quad (4)$$

con $v_{\text{sonido}} \approx 343$ m/s. Un chirp más corto reduce $R_{\min}$, pero también reduce la energía transmitida y el número de ciclos de su componente de menor frecuencia, degradando la relación señal-ruido del eco. El diseño de la señal transmitida es, en consecuencia, un compromiso entre rango mínimo alcanzable y confiabilidad de detección.

D. Restricciones de la implementación embebida

A diferencia del prototipo en Python, la implementación en el ESP32 opera bajo restricciones de tiempo real y de memoria (una pila de ejecución de tamaño fijo, sin asignación dinámica para estructuras grandes). La generación de la señal




Fig. 1. Tiempo de ejecución de la DFT directa contra la FFT propia, en escala lineal y log-log, para N entre 16 y 4096 muestras.

transmitida se controla mediante una interrupción de temporizador de hardware, mientras que la captura del micrófono se implementa como un lazo de espera activa temporizado por software, una asimetría de diseño que se retoma en la Sección III-D. Además, el núcleo Xtensa del ESP32 posee unidad de punto flotante de precisión simple (`float`) pero no de precisión doble (`double`), evaluada por software y notablemente más lenta. La implementación embebida actual, sin embargo, usa `double` en casi todos sus cálculos – heredado de la biblioteca de FFT empleada –, pagando en la práctica ese costo de emulación; migrar a `float` donde la precisión lo permita queda pendiente (Sección V).

III. METODOLOGÍA Y RESULTADOS EXPERIMENTALES

A. Validación de la DFT y la FFT propias

Se implementaron tres variantes de la transformada – DFT directa por ciclo explícito, DFT directa vectorizada como producto matriz-vector, y FFT recursiva radix-2, junto con su inversa mediante la propiedad $\text{ifft}(X) = \text{fft}(\overline{X})/N$ – y se validaron contra `numpy.fft` usando una señal aleatoria de $N = 16$ muestras, obteniendo un error absoluto máximo del orden de 10^{-14} a 10^{-15} , y de 10^{-16} para la reconstrucción $\text{ifft}(\text{fft}(x)) = x$, lo que confirma la correctitud de las tres implementaciones.

Posteriormente se midió el tiempo de ejecución de la DFT matricial y de la FFT propia para $N = 2^4, 2^5, \dots, 2^{12}$ (16 a 4096 muestras), tomando el mínimo de cinco repeticiones por punto. La Fig. 1 resume los resultados. Para $N \leq 128$ la DFT vectorizada resulta incluso más rápida que la FFT recursiva, debido al costo de las llamadas recursivas en Python; a partir de $N \approx 256$ el crecimiento cuadrático de la DFT se hace evidente, y en $N = 4096$ la DFT tarda 497.3 ms frente a apenas 17.2 ms de la FFT propia, casi 29 veces más lenta, consistente con las complejidades teóricas $O(N^2)$ y $O(N \log N)$.

Adicionalmente, se generaron señales de prueba de tono puro y de tono con fase inicial distinta de cero, confirmando que la FFT propia preserva correctamente tanto la magnitud como la fase de cada componente frecuencial, y que para una señal compuesta por dos tonos cada componente aparece como un pico independiente con su propia magnitud y fase, en concordancia con la linealidad de la transformada de Fourier.




Fig. 2. Detección de tres ecos simultáneos (retardos de 480, 900 y 1400 muestras) en presencia de ruido gaussiano. Ambos métodos identifican correctamente las tres posiciones reales.

B. Detección de ecos por correlación: caso ideal, ruido y ecos múltiples

Utilizando el chirp de 2–8 kHz con duración de 5 ms como señal transmitida, se simuló un único eco con retardo conocido y se verificó que tanto la correlación directa como la correlación mediante FFT ubican el pico exactamente en la posición del retardo real. Posteriormente se simularon tres ecos simultáneos de amplitudes decrecientes (0.6, 0.35 y 0.2) en los retardos 480, 900 y 1400 muestras, y ambos métodos identificaron correctamente las tres posiciones, con magnitudes de correlación proporcionales a la amplitud de cada reflexión.

Para evaluar la robustez ante ruido se agregó ruido gaussiano a la señal recibida con relaciones señal-ruido de 20, 10, 0 y -5 dB. Incluso en el caso más adverso (-5 dB, donde la potencia del ruido supera a la de la señal), el pico de correlación correspondiente al retardo real se mantuvo claramente distinguible del piso de ruido (Fig. 2), lo que evidencia la ganancia de procesamiento que aporta la correlación como filtro adaptado frente a la detección directa sobre la señal en el dominio del tiempo.

C. Correlación directa contra correlación mediante FFT

Se comparó el tiempo de ejecución de ambos métodos de correlación para N entre 64 y 1024 muestras (Fig. 3). Para ventanas pequeñas, la correlación directa resulta comparable o incluso más rápida que la basada en FFT, debido al costo fijo del *zero-padding* y del cálculo de las tres transformadas involucradas; a partir de aproximadamente $N \approx 500$ muestras la correlación mediante FFT empieza a mostrar una ventaja creciente, siendo evidente en $N = 1024$ (147.8 ms para la correlación directa contra 53.9 ms para la basada en FFT).

D. Implementación en hardware

La arquitectura del sistema embebido se resume en la Fig. 4. Un temporizador de hardware dispara, a 24 kHz,




Fig. 3. Tiempo de ejecución de la correlación directa contra la correlación mediante FFT, para N entre 64 y 1024 muestras.




Fig. 4. Arquitectura actual del sistema embebido. La captura del micrófono ya no depende de una segunda interrupción de hardware. A partir de la misma ventana recibida se calculan tres candidatos de distancia en paralelo – correlación directa, correlación mediante FFT y una estimación por resta contra una calibración base sin objeto –, además de un espectro FFT independiente solo con fines de diagnóstico. Los tres candidatos se imprimen por el puerto serie; todavía no existe una regla que elija uno solo como salida oficial, y la pantalla LCD prevista en el diseño original aún no está integrada.

la salida sucesiva de las muestras del chirp precalculado (48 muestras, 2 ms) hacia el conversor digital-analógico que excita el altavoz a través de un amplificador clase D externo. La captura del micrófono, en cambio, no usa una segunda interrupción de hardware: es un lazo de espera activa temporizado por software (`micros()` con corrección de residuo) que toma 256 muestras a 24 kHz justo después de disparar el chirp. Esta asimetría simplifica el diseño a costa de bloquear el ciclo principal durante los aproximadamente 10.7 ms de la ventana de recepción, lo cual no afecta la cadencia general porque el sistema de todos modos espera 1 s entre capturas.

A diferencia de una iteración anterior del firmware, que estimaba el retardo únicamente con correlación directa, la versión actual calcula en cada ciclo *tres* candidatos de distancia

en paralelo, sin que ninguno se declare todavía como salida oficial. Los dos primeros – correlación directa y correlación mediante FFT (con la biblioteca `arduinoFFT`, no la FFT propia de la Sección III-A, reservada al prototipo en Python) – comparten la misma regla de selección: en vez del máximo global de la ventana, toman el *primer* máximo local que supera un umbral relativo tras el guarda, asumiendo que la reflexión más cercana por encima del ruido es el objetivo. Esta regla reemplazó a una versión que tomaba el pico de mayor magnitud en toda la ventana, vulnerable a reflexiones fijas del entorno con correlación comparable o mayor que el eco real conforme el objetivo se aleja. El tercer candidato resta, muestra a muestra, la correlación FFT actual contra una calibración base capturada una vez al inicio sin objeto; aquí sí se conserva el máximo global entre los picos sobre el umbral, pues tras restar el entorno estático el pico remanente más fuerte debería ser el objeto nuevo. Los tres candidatos se imprimen por el puerto serie para comparación manual durante esta etapa de ajuste.

La distancia de cada candidato se obtiene acumulando el tiempo transcurrido, en microsegundos, entre el instante de emisión del chirp y el retardo de muestras en el que su correlación correspondiente alcanza el pico seleccionado, aplicando $R = v_{\text{sonido}} \tau / 2$. El intervalo de guarda ya no se fija de forma ad-hoc para exceder la duración del chirp, sino que se deriva directamente de la fórmula de rango mínimo de la Sección II-C: para un rango mínimo de diseño de 15 cm, guarda = $\lceil 2 \times 0.15 / v_{\text{sonido}} \times F_s \rceil \approx 21$ muestras a $F_s = 24$ kHz. La ventana de búsqueda del pulso directo (la referencia $\tau = 0$) también se redujo de 60 a 30 muestras respecto a una iteración anterior, para disminuir el riesgo de que dicha búsqueda confunda el eco de un objeto muy cercano con la fuga directa entre altavoz y micrófono.

El compromiso de la Sección II-C entre rango mínimo y confiabilidad sigue en ajuste empírico. En las pruebas más recientes, los tres candidatos coinciden y reportan la distancia correcta a 15 cm y a 22 cm, consistente con $R_{\min}$ para la duración de chirp actual. Más allá de esa distancia, el sistema no elige consistentemente el candidato correcto: el eco del objeto se debilita mientras las reflexiones fijas del entorno mantienen magnitud aproximadamente constante, de modo que la regla de “primer pico” puede fijarse en un blip cercano espúreo y la de “mayor cambio” en una reflexión que la calibración no canceló por completo. Resolver esta ambigüedad es el problema abierto principal del proyecto, y se discute en la Sección V.

IV. CONCLUSIONES

Las implementaciones propias de la DFT, la FFT y la correlación cruzada fueron validadas numéricamente contra una referencia estándar, confirmando su correctitud antes de emplearlas en un sistema en tiempo real. La comparación de tiempos evidenció, de forma cuantitativa, la ventaja asintótica de la FFT sobre la DFT directa, así como el hecho de que esa ventaja depende del tamaño de la ventana procesada: para las ventanas pequeñas utilizadas en el radar embebido,

la correlación directa resultó preferible, mientras que para ventanas mayores la correlación mediante FFT sería la opción más eficiente. Los experimentos con ruido y con ecos múltiples demostraron que la correlación cruzada, al actuar como filtro adaptado, permite detectar el retardo correcto incluso cuando la señal recibida está fuertemente contaminada por ruido o compuesta por varias reflexiones superpuestas. Finalmente, la implementación en el ESP32 demostró que es posible construir, con recursos de bajo costo, un radar acústico funcional que reporta distancias correctas y repetibles en el rango cercano validado hasta ahora (15 cm y 22 cm). El proceso de llevar el sistema a hardware real también expuso algo que el prototipo en Python, sin clutter físico, no podía anticipar: pasada cierta distancia, distinguir el eco del objeto de las reflexiones fijas del entorno deja de ser trivial, y la estrategia de selección de picos sigue en ajuste.

V. RECOMENDACIONES

La prioridad inmediata es resolver la ambigüedad de la Sección III-D entre los tres candidatos de distancia. Se recomienda promover el candidato por resta contra calibración a salida única – ataca directamente el clutter fijo del entorno – y validarlo con un barrido sistemático de 15 a 60 cm en pasos de 5 cm, en vez de puntos sueltos.

Como optimizaciones adicionales: migrar los cálculos de `double` a `float` donde la precisión lo permita, ya que el núcleo Xtensa solo tiene unidad de punto flotante de precisión simple (Sección II-D); evaluar DMA para la captura del micrófono, que hoy depende de un lazo de espera activa por software; y filtrar la señal capturada a la banda 2-8 kHz antes de correlacionar. Una vez validado un candidato confiable en todo el rango de diseño, se recomienda integrar la pantalla LCD prevista originalmente (aún no conectada) y automatizar la calibración base al arranque.

REFERENCES

- [1] A. V. Oppenheim and R. W. Schaffer, *Discrete-Time Signal Processing*, 3rd ed. Upper Saddle River, NJ, USA: Prentice Hall, 2010.
- [2] J. W. Cooley and J. W. Tukey, “An algorithm for the machine calculation of complex Fourier series,” *Math. Comput.*, vol. 19, no. 90, pp. 297–301, 1965.
- [3] M. I. Skolnik, *Introduction to Radar Systems*, 3rd ed. New York, NY, USA: McGraw-Hill, 2001.
- [4] M. A. Richards, *Fundamentals of Radar Signal Processing*, 2nd ed. New York, NY, USA: McGraw-Hill, 2014.
- [5] J. G. Proakis and D. G. Manolakis, *Digital Signal Processing: Principles, Algorithms, and Applications*, 4th ed. Upper Saddle River, NJ, USA: Pearson, 2007.
- [6] Espressif Systems, “ESP32 Series Datasheet,” version 4.6, 2023. [Online]. Available: <https://www.espressif.com>